Equipo 2 – Ground Truth y control del benchmark

Plan de trabajo en dos sprints

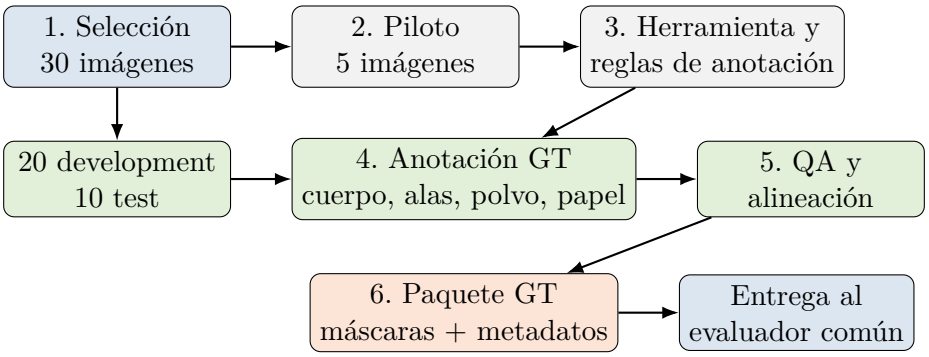
Objetivo principal. Construir y validar el Ground Truth (GT) común que utilizarán todos los equipos para evaluar sus metodologías de limpieza bajo las mismas imágenes, regiones y anotaciones de referencia.

Objetivos secundarios.

- seleccionar las 30 imágenes representativas del benchmark y dividirlas en 20 de desarrollo y 10 de evaluación;
- definir y aplicar un protocolo único de anotación para cuerpo, alas, motas de polvo y región de papel/etiqueta;
- seleccionar o terminar una herramienta de anotación que permita trabajar con rapidez sin modificar la resolución original;
- verificar la calidad y alineación de todas las máscaras antes de entregarlas al evaluador del Equipo 1;
- mantener una estructura de archivos y metadatos común, reproducible y reutilizable;
- en el Sprint 2, aplicar uno o dos métodos adicionales de limpieza utilizando exactamente el mismo benchmark.

Avance actual. El equipo ya exploró CVAT y Supervisely. Debido a la fricción encontrada para utilizarlos en el entorno disponible, se inició una herramienta interna de escritorio. El prototipo ya muestra resultados útiles para cuerpo y alas, mientras que la detección automática de motas todavía no es suficientemente confiable. Por ello, durante este proyecto la aplicación interna se considerará principalmente una **herramienta de anotación asistida**, no un producto a desarrollar ni una fuente automática del GT.

Mapa general al finalizar el Sprint 1



Idea central: el GT debe ser independiente de los métodos que después serán evaluados. La asistencia automática puede acelerar la segmentación, pero las máscaras finales y las motas de referencia deben ser revisadas por una persona.

Sprint 1 – Construcción del Ground Truth

Sprint Goal. Al finalizar el sprint deberá existir un paquete GT completo, consistente y validado para las 30 imágenes, listo para ser utilizado por el evaluador común sin necesidad de reinterpretar las anotaciones.

Entregable 1. Selección y división de las 30 imágenes

Qué debe aportar. Un conjunto pequeño pero representativo que permita desarrollar métodos y posteriormente compararlos de forma justa.

División propuesta:

- **20 imágenes de development**: visibles durante el desarrollo y ajuste de los métodos.
- **10 imágenes de test**: reservadas para la comparación final; sus anotaciones no deben utilizarse para ajustar parámetros.

La selección debe incluir diversidad de tamaño, color, número y tipo de motas, proximidad de las motas al ejemplar, presencia de papel/etiqueta y casos fáciles/difíciles. No es necesario maximizar la cantidad; es preferible un conjunto de 30 imágenes bien seleccionado y bien anotado.

Ejemplo de registro.

```
IMG_012 | JPEG | polvo medio | mota cerca del ala | con papel
IMG_018 | RAW  | pocas motas | fondo uniforme     | sin etiqueta
```

Entregable 2. Piloto de anotación con 5 imágenes

Qué debe aportar. Confirmar la herramienta y el protocolo antes de invertir tiempo en las 30 imágenes.

En las 5 imágenes piloto se deberá probar el flujo completo: cargar, segmentar, corregir manualmente, guardar, reabrir y exportar. Se registrará de forma aproximada el tiempo por imagen y los problemas encontrados.

Criterios mínimos para aceptar la herramienta:

- conservar exactamente ancho y alto de la imagen original;
- permitir corrección manual de la segmentación asistida;
- exportar máscaras alineadas píxel a píxel con el original;
- guardar y reabrir anotaciones sin alterar su posición;
- permitir distinguir las clases de anotación acordadas;
- no exigir desarrollar funciones ajenas al objetivo del GT.

Sobre la app interna. Si el prototipo propio cumple estos puntos, puede utilizarse. No es necesario convertirlo en una aplicación completa: interfaz bonita, reportes avanzados, detección automática perfecta de polvo o instaladores sofisticados quedan fuera del Sprint 1.

Entregable 3. Protocolo de anotación

Qué debe aportar. Reglas suficientemente claras para que dos personas interpreten las regiones de forma similar.

Clases mínimas:

- **body/specimen**: cuerpo y estructuras del ejemplar según la convención acordada;
- **wings**: alas como región independiente para permitir evaluación estructural específica;
- **dust**: motas de polvo reales, preferentemente registradas como instancias individuales además de una máscara global;

- **paper/info**: papel milimétrico, etiqueta o región informativa, mantenida separada del ejemplar.

Para las motas se recomienda registrar al menos un identificador y su región. Si una mota se encuentra sobre la libélula o una zona protegida, puede anotarse igualmente, pero debe marcarse como **no limpiable automáticamente**; su existencia no autoriza a los métodos a modificar el espécimen.

Ejemplo conceptual:

```
MOTA_007
zona: fondo
accionable: si

MOTA_008
zona: ala
accionable: no
```

Entregable 4. Anotación completa del Ground Truth

Qué debe aportar. Las máscaras y anotaciones que servirán como referencia única para todos los equipos.

Cada imagen deberá conservar su original y sus anotaciones bajo un ID estable. Una estructura posible es:

```
IMG_001/
  original.jpg
  specimen_mask.png
  wings_mask.png
  dust_mask.png
  info_mask.png
  dust_instances.json
```

La herramienta empleada puede generar otros formatos internos, pero el paquete final debe exportarse a un formato sencillo que el evaluador común pueda leer sin depender de la aplicación de anotación.

Entregable 5. Control de calidad (QA) del GT

Qué debe aportar. Evidencia de que las máscaras están bien alineadas y las anotaciones son suficientemente consistentes.

Pruebas mínimas:

- comprobar que cada máscara tenga exactamente la resolución del original;
- superponer visualmente máscara e imagen para detectar desplazamientos;
- verificar que cuerpo y alas correspondan a la región correcta;
- revisar las motas una a una en un subconjunto de control;
- comprobar nombres e IDs de los archivos;
- reabrir una muestra de anotaciones para confirmar que no cambiaron durante exportación.

Se recomienda que ambos integrantes anoten de forma independiente al menos las mismas **5 imágenes** y posteriormente comparen discrepancias. No se busca un estudio formal de variabilidad interanotador; la prueba sirve para detectar reglas ambiguas antes de finalizar el GT.

Entregable 6. Paquete final del benchmark

Qué debe aportar. Un paquete que pueda utilizarse inmediatamente por el Equipo 1 y por cualquier metodología futura.

```
benchmark/
  development/
    images/
    annotations/
  test/
    images/
    annotations/        # mantener fuera del ajuste de metodos
  README.md
  annotation_rules.md
  metadata.csv
```

El `README` debe explicar nombres, clases, formatos y estructura. El archivo de reglas debe describir decisiones de anotación que no sean evidentes a partir de las máscaras.

Definition of Done – Sprint 1

El sprint se considera terminado cuando:

- se seleccionaron las 30 imágenes y existe la división 20 development / 10 test;
- la herramienta de anotación fue validada con 5 imágenes piloto;
- existe un protocolo de anotación corto y común;
- las 30 imágenes cuentan con las máscaras acordadas y las motas están registradas;
- las máscaras pasaron controles de resolución, alineación y consistencia;
- existe un paquete GT independiente del software utilizado para anotarlo;
- el Equipo 1 puede consumir el formato acordado sin esperar cambios manuales por imagen.

Sprint 2 – Aplicación de metodologías adicionales

Objetivo principal. Utilizar el benchmark ya congelado para generar resultados con uno o dos métodos de limpieza adicionales y compararlos bajo el mismo evaluador utilizado por los demás equipos.

Objetivos secundarios.

- seleccionar métodos viables sin convertir el sprint en un nuevo proyecto de desarrollo;
- producir outputs sobre development siguiendo las reglas del benchmark;
- elegir una configuración final sin utilizar el GT de test para reajustarla;
- ejecutar el método final sobre test y entregar los resultados al evaluador común;
- documentar dificultades prácticas, tiempo de uso y casos de fallo.

Entregables generales.

1. Método(s) adicional(es) seleccionado(s) y breve justificación.

2. Parámetros o procedimiento reproducible.
3. Imágenes de salida con IDs compatibles con el benchmark.
4. CSV producido por el evaluador común.
5. Recomendación breve con ventajas, limitaciones y tiempo de operación.

Principio de trabajo. El GT debe permanecer fijo durante el Sprint 2. Si una metodología revela un posible error de anotación, el caso se registra y se revisa de forma controlada; no se modifica el GT únicamente para mejorar el resultado de un método.